

Глава 3

Статистические модели

Проект. Определение перспективного тарифа для телеком-компаний

Описание проекта

Вы аналитик компании «Мегалайн2». Клиентам предлагают два тарифных плана: «Смарт» и «Базовый». Чтобы скорректировать рекламный бюджет, коммерческий департамент хочет понять, какой тариф приносит больше денег.

Вам предстоит сделать предварительный анализ тарифов на небольшой выборке клиентов. В вашем распоряжении данные 500 пользователей «Мегалайн2»: кто они, откуда, каким тарифом пользуются, сколько звонков и сообщений каждый отправил за 2018 год. Нужно проанализировать поведение клиентов и сделать вывод – какой тариф лучше.

Описание тарифов

Тариф «Базовый»

1. Ежемесячная плата: 550 рублей
2. Включено 500 минут разговора, 50 сообщений и 15 Гб интернет-трафика
3. Стоимость услуг сверх тарифного пакета:
 - минута разговора: 3 рубля
 - сообщение: 3 рубля
 - 1 Гб интернет-трафика: 200 рублей

Тариф «Смарт»

1. Ежемесячная плата: 1950 рублей
2. Включено 3000 минут разговора, 1000 сообщений и 30 Гб интернет-трафика
3. Стоимость услуг сверх тарифного пакета:
 - минута разговора: 1 рубль
 - сообщение: 1 рубль
 - 1 Гб интернет-трафика: 150 рублей

Примечание

«Мегалайн2» всегда округляет секунды до минут, а мегабайты – до гигабайт. Каждый звонок округляется отдельно: даже если он длился всего 1 секунду, будет засчитан как 1 минута.

Для веб-трафика отдельные сессии не считаются. Вместо этого общая сумма за месяц округляется в бо́льшую сторону. Если абонент использует 1025 мегабайт в этом месяце, с него возьмут плату за 2 гигабайта. Неиспользованные за предыдущий месяц звонки, смс, интернет на следующий месяц не переносятся.

Инструкция по выполнению проекта

Шаг 1. Откройте файлы с данными и изучите общую информацию

Шаг 2. Подготовьте данные

- Приведите данные к нужным типам;
- Найдите и исправьте ошибки в данных, если они есть.

Поясните, какие ошибки вы нашли и как их исправили. В данных вы найдёте звонки с нулевой продолжительностью – это пропущенные звонки.

Посчитайте для каждого пользователя:

- количество сделанных звонков и израсходованных минут разговора по месяцам;
- количество отправленных сообщений по месяцам;
- объем израсходованного интернет-трафика по месяцам;
- месячную выручку с каждого пользователя (вычтите бесплатный лимит из суммарного количества звонков, сообщений и интернет-трафика; остаток умножьте на значение из тарифного плана; прибавьте абонентскую плату, соответствующую тарифному плану).

Шаг 3. Проанализируйте данные

Опишите поведение клиентов оператора, исходя из выборки. Сколько минут разговора, сколько сообщений и какой объём интернет-трафика требуется пользователям каждого тарифа в месяц? Посчитайте среднее количество, дисперсию и стандартное отклонение. Постройте гистограммы. Опишите распределения.

Шаг 4. Проверьте гипотезы

- средняя выручка пользователей тарифов «Базовый» и «Смарт» различаются;
- средняя выручка пользователей из Москвы отличается от выручки пользователей из других регионов.

Пороговое значение α задайте самостоятельно.

Поясните:

- как вы формулировали нулевую и альтернативную гипотезы;
- какой критерий использовали для проверки гипотез и почему.

Шаг 5. Напишите общий вывод

Описание данных

Таблица *users* (информация о пользователях):

- *user_id* – уникальный идентификатор пользователя
- *first_name* – имя пользователя
- *last_name* – фамилия пользователя
- *age* – возраст пользователя (годы)
- *reg_date* – дата подключения тарифа (день, месяц, год)
- *churn_date* – дата прекращения пользования тарифом (если значение пропущено, то тариф ещё действовал на момент выгрузки данных)
- *city* – город проживания пользователя
- *tariff* – название тарифного плана

Таблица *calls* (информация о звонках):

- *id* – уникальный номер звонка
- *call_date* – дата звонка
- *duration* – длительность звонка в минутах
- *user_id* – идентификатор пользователя, сделавшего звонок

Таблица *messages* (информация о сообщениях):

- *id* – уникальный номер сообщения
- *message_date* – дата сообщения
- *user_id* – идентификатор пользователя, отправившего сообщение

Таблица *internet* (информация об интернет-сессиях):

- *id* – уникальный номер сессии
- *mb_used* – объём потраченного за сессию интернет-трафика (в мегабайтах)
- *session_date* – дата интернет-сессии
- *user_id* – идентификатор пользователя

Таблица *tariffs* (информация о тарифах):

- *tariff_name* – название тарифа
- *rub_monthly_fee* – ежемесячная абонентская плата в рублях
- *minutes_included* – количество минут разговора в месяц, включённых в абонентскую плату
- *messages_included* – количество сообщений в месяц, включённых в абонентскую плату
- *mb_per_month_included* – объём интернет-трафика, включённого в абонентскую плату (в мегабайтах)
- *rub_per_minute* – стоимость минуты разговора сверх тарифного пакета (например, если в тарифе 100 минут разговора в месяц, то со 101 минуты будет взиматься плата)
- *rub_per_message* – стоимость отправки сообщения сверх тарифного пакета
- *rub_per_gb* – стоимость дополнительного гигабайта интернет-трафика сверх тарифного пакета (1 гигабайт = 1024 мегабайта)