

Глава 3

Статистические модели

Проект. Стратегия взаимодействия с клиентами фитнес-центра

Описание проекта

Сеть фитнес-центров «Культурист-датасаентист» разрабатывает стратегию взаимодействия с пользователями на основе аналитических данных.

Распространённая проблема фитнес-клубов и других сервисов – **отток клиентов**. Как понять, что пользователь больше не с вами? Можно записать в отток тех, кто попросил закрыть договор или удалил аккаунт. Однако клиенты не всегда уходят демонстративно: чаще перестают пользоваться сервисом тихо.

Индикаторы оттока зависят от специфики отрасли. Когда пользователь редко, но стабильно закупается в интернет-магазине – не похоже, что он «отвалился». А вот если две недели не заходит на канал с ежедневно обновляемым контентом, дела плохи: подписчик заскучал и, кажется, оставил вас.

Для фитнес-центра можно считать, что клиент попал в отток, если за последний месяц ни разу не посетил спортзал. Конечно, не исключено, что он уехал на Бали и по приезде обязательно продолжит ходить на фитнес. Однако чаще бывает наоборот. Если клиент начал новую жизнь с понедельника, немного походил в спортзал, а потом пропал – скорее всего, он не вернётся.

Чтобы бороться с оттоком, отдел по работе с клиентами «Культуриста-датасаентиста» перевёл в электронный вид множество анкет пользователей. Ваша задача – провести анализ и подготовить план действий по удержанию клиентов.

А именно:

1. научиться прогнозировать вероятность оттока (на уровне следующего месяца) для каждого клиента;
2. сформировать типичные портреты пользователей: выделить несколько наиболее ярких групп и охарактеризовать их основные свойства;
3. проанализировать основные признаки, наиболее сильно влияющие на отток;
4. сформулировать основные выводы и разработать рекомендации по повышению качества работы с клиентами:
 - выделить целевые группы клиентов;
 - предложить меры по снижению оттока;
 - определить другие особенности взаимодействия с клиентами.

Инструкция по выполнению проекта

Шаг 1. Загрузите данные

«Культурист-датасаентист» предоставил сведения в csv-файле. Заказчик подготовил данные, которые содержат данные на месяц до оттока и факт оттока на определённый месяц. Набор данных включает следующие поля:

Данные пользователя за предыдущий до проверки факта оттока месяц:

- 'gender' – пол
- 'Near_Location' – проживание или работа в районе, где находится фитнес-центр
- 'Partner' – сотрудник компании-партнёра клуба (сотрудничество с компаниями, чьи сотрудники могут получать скидки на абонемент – в таком случае фитнес-центр хранит информацию о работодателе клиента)
- 'Promo_friends' – факт первоначальной записи в рамках акции «приведи друга» (использовал промо-код от знакомого при оплате первого абонемента)
- 'Phone' – наличие контактного телефона
- 'Age' – возраст
- 'Lifetime' – время с момента первого обращения в фитнес-центр (в месяцах)

Информация на основе журнала посещений, покупок и информация о текущем статусе абонемента клиента

- 'Contract_period' – длительность текущего действующего абонемента (месяц, 3 месяца, 6 месяцев, год)
- 'Month_to_end_contract' – срок до окончания текущего действующего абонемента (в месяцах)
- 'Group_visits' – факт посещения групповых занятий
- 'Avg_class_frequency_total' – средняя частота посещений в неделю за все время с начала действия абонемента
- 'Avg_class_frequency_current_month' – средняя частота посещений в неделю за предыдущий месяц
- 'Avg_additional_charges_total' – суммарная выручка от других услуг фитнес-центра: кафе, спорт-товары, косметический и массажный салон

'Churn' – факт оттока в текущем месяце.

Шаг 2. Проведите исследовательский анализ данных

- Посмотрите на датасет: есть ли в нём отсутствующие значения (пропуски), изучите средние значения и стандартные отклонения (пригодится метод `describe()`);
- Посмотрите на средние значения признаков в двух группах – тех, кто ушел в отток и тех, кто остался (воспользуйтесь методом `groupby()`);
- Постройте столбчатые гистограммы и распределения признаков для тех, кто ушёл (отток) и тех, кто остался (не попали в отток);
- Постройте матрицу корреляций и отобразите её.

Шаг 3. Постройте модель прогнозирования оттока пользователей

Постройте модель бинарной классификации пользователей, где целевой признак – факт оттока пользователя в следующем месяце:

- Разбейте данные на обучающую и валидационную выборку функцией `train_test_split()`.
- Обучите модель на train-выборке двумя способами:

- 1) логистической регрессией
 - 2) случайным лесом
- Оцените метрики **accuracy**, **precision** и **recall** для обеих моделей на валидационной выборке. Сравните по ним модели. Какая модель показала себя лучше на основании метрик?

Не забудьте указать параметр `random_state` при разделении выборки и задании алгоритма.

Шаг 4. Сделайте кластеризацию пользователей

Отложите в сторону столбец с оттоком и проведите кластеризацию объектов (клиентов):

- Стандартизируйте данные.
- Постройте матрицу расстояний функцией `linkage()` на стандартизированной матрице признаков и нарисуйте дендрограмму. Внимание: отрисовка дендрограммы может занять время! На основании полученного графика предположите, какое количество кластеров можно выделить.
- Обучите модель кластеризации на основании алгоритма K-Means и спрогнозируйте кластеры клиентов.
- Посмотрите на средние значения признаков для кластеров. Можно ли сразу что-то заметить?
- Постройте распределения признаков для кластеров. Можно ли что-то заметить по ним?
- Для каждого полученного кластера посчитайте долю оттока (методом `groupby()`). Отличаются ли они по доле оттока? Какие кластеры склонны к оттоку, а какие – надёжны?

Шаг 5. Сформулируйте выводы и сделайте базовые рекомендации по работе с клиентами

Сформулируйте основные выводы и предложите рекомендации для стратегии взаимодействия с пользователями и их удержания.

Не описывайте стратегию детально: достаточно 3-4 важных принципов и примеров их реализации в виде определённых маркетинговых действий.